

La progettazione logica di una base di dati: ristrutturazione dello schema concettuale

Prof. Giuseppe Perelli
perelli@di.uniroma1.it



SAPIENZA
UNIVERSITÀ DI ROMA



DUE TIPI PRINCIPALI DI MODELLI

- **modelli logici:** indipendenti dalle strutture fisiche ma disponibili nei DBMS: es. reticolare (network), gerarchico (hierarchical), relazionale (relational), ad oggetti (object)
- **modelli concettuali:** indipendenti dalle modalità di realizzazione, hanno lo scopo di rappresentare le entità del mondo reale e le loro relazioni nelle prime fasi della progettazione: es. entità-relazioni (entity-relationship)



MEMORIZZAZIONE VS. ACCESSO


I sistemi di basi di dati utilizzano file in formati proprietary per memorizzare i dati

ma

offrono agli utenti una vista astratta dei dati, in modo da rendere trasparenti i dettagli di memorizzazione e manipolazione



I TRE LIVELLI DI ASTRAZIONE DI UN DB





I TRE LIVELLI DI ATRAZIONE DI UN DB

- **Schema esterno**: descrizione di una porzione della base di dati in un modello logico attraverso “viste” parziali, o derivate, che possono prevedere organizzazioni dei dati diverse rispetto a quelle utilizzate nello schema logico, e che riflettono esigenze e privilegi di accesso di particolari tipologie di utenti; ad uno schema logico si possono associare più schemi esterni
- **Schema logico**: descrizione dell'intera base di dati nel modello logico “principale” del DBMS, ad esempio la struttura delle tabelle
- **Schema fisico**: rappresentazione dello schema logico per mezzo di strutture fisiche di memorizzazione, cioè i file



ACCESSO AI DATI

Gli accessi alla base di dati avvengono solamente attraverso lo schema esterno, che può coincidere completamente con lo schema logico.



INDIPENDENZA DEI DATI

Indipendenza fisica

il livello logico e quello esterno sono indipendenti da quello fisico

- una relazione è utilizzata nello stesso modo qualunque sia la sua realizzazione fisica (organizzazione dei file e loro allocazione fisica)
- la realizzazione fisica può cambiare senza che debbano essere modificati i programmi



INDIPENDENZA DEI DATI

Indipendenza logica

il livello esterno è indipendente da quello logico

- aggiunte o modifiche alle viste non richiedono modifiche al livello logico
- modifiche allo schema logico che lascino inalterato lo schema esterno sono trasparenti



SCHEMI E ISTANZE

- In ogni base di dati esistono:
 - lo schema, sostanzialmente invariante nel tempo, che ne descrive la struttura (aspetto intensionale): nel modello relazionale, le intestazioni delle tabelle = lista di nomi di attributi e loro tipi
 - l'istanza, i valori attuali, che possono cambiare anche molto rapidamente (aspetto estensionale): nel modello relazionale, il “corpo” di ciascuna tabella



SCHEMI E ISTANZE

ANAGRAFICA

NOME	COGNOME	DATA_N	LUOGO_N
Piero	Napoli	22-10-63	Bari
Marco	Bianchi	01-05-54	Roma
Maria	Rossi	09-02-68	Milano
Maria	Bianchi	07-12-70	Bari
Paolo	Sossi	15-03-75	Palermo



SCHEMI E ISTANZE

ANAGRAFICA

NOME	COGNOME	DATAN	LUOGON
Piero	Napoli	22-10-63	Bari
Marco	Bianchi	01-05-54	Roma
Maria	Rossi	09-02-68	Milano
Maria	Bianchi	07-12-70	Bari
Paolo	Sossi	15-03-75	Palermo

SCHEMA



SCHEMI E ISTANZE

ANAGRAFICA

NOME	COGNOME	DATAN	LUOGON
Piero	Napoli	22-10-63	Bari
Marco	Bianchi	01-05-54	Roma
Maria	Rossi	09-02-68	Milano
Maria	Bianchi	07-12-70	Bari
Paolo	Sossi	15-03-75	Palermo

ISTANZA



LINGUAGGI PER LE BASI DI DATI

- **data definition language (DDL)**
 - per la definizione di **schemi** (logici, esterni, fisici) e altre operazioni generali
- **data manipulation language (DML)**
 - per l'interrogazione e l'aggiornamento di (**istanze** di) basi di dati
- **SQL** (Structured Query Language) è un linguaggio standardizzato per database basati sul modello relazionale (RDBMS)
- In SQL i due tipi di funzionalità sono integrate in un unico linguaggio di comandi



MODELLO RELAZIONALE

- Basato sulla nozione matematica di relazione
- Le relazioni si traducono in maniera naturale in tabelle (infatti useremo sempre il termine relazione invece di tabella)
- Dati e relazioni (riferimenti) tra dati di insiemi (tabelle) diversi sono rappresentati come valori
- **ATTENZIONE** ai diversi significati con cui può essere utilizzato il termine relazione



Passiamo dal modello concettuale
al modello logico relazionale
della base di dati



OBIETTIVO DELLA PROGETTAZIONE LOGICA

- "tradurre" lo schema concettuale in uno schema logico che rappresenti gli stessi dati in maniera corretta (ed efficiente) rispetto al modello prescelto
- ci concentriamo sulla correttezza (non considereremo l'efficienza)



DATI DI INGRESSO E USCITA

- Ingresso:
 - schema concettuale
 - documentazione associata
 - modello logico
- Uscita:
 - schema logico
 - documentazione associata



Non si tratta di una pura e semplice traduzione per due motivi:

- alcuni aspetti non sono direttamente rappresentabili
- è necessario prestare attenzione alle prestazioni (out of scope)



Articolazione in fasi della progettazione logica



RISTRUTTURAZIONE SCHEMA E-R

- Motivazioni:
 - semplificare la traduzione
 - ottimizzare le prestazioni (ma noi non lo faremo)
- Osservazione:
- uno schema E-R ristrutturato è meno concettuale perché cominciamo a tenere conto del modello logico adottato (e quindi dei dettagli implementativi)

Indicatori per l'efficienza

- spazio: determinato dal numero di occorrenze previste per entità ed associazioni
- 'tempo': numero di occorrenze (di entità e associazioni) visitate durante un'operazione



ATTIVITÀ DELLA RISTRUTTURAZIONE

- Analisi delle ridondanze ... (tralasciamo la versione più rigorosa)
- Eliminazione delle generalizzazioni
- Partizionamento/accorpamento di entità e relazioni
- Scelta degli identificatori primari



ANALISI DELLE RIDONDANZE

- Una ridondanza in uno schema E-R è una informazione significativa ma derivabile da altre
- in questa fase si decide se eliminare le ridondanze eventualmente presenti o mantenerle




FORME DI RIDONDANZA IN UNO SCHEMA E-R

- attributi derivabili:
 - da altri attributi della stessa entità (o relazione)
 - da attributi di altre entità (o relazioni)
 - da operazioni di conteggio sulla partecipazione ad associazioni
- relazioni derivabili dalla composizione di altre relazioni in presenza di cicli




ATTRIBUTO DERIVABILE






ATTRIBUTO DERIVABILE DA ALTRA ENTITÀ





ATTRIBUTO DERIVABILE PER CONTEGGIO




Ridondanza dovuta a ciclo



SAPIENZA
UNIVERSITÀ DI ROMA
DIPARTIMENTO DI INFORMATICA

ATTENZIONE: abbiamo
una ridondanza soltanto
se nei due percorsi
otteniamo gli **stessi dati**





ATTIVITÀ DELLA RISTRUTTURAZIONE

- (Analisi delle ridondanze)
- Eliminazione delle generalizzazioni
- Partizionamento/accorpamento di entità e relazioni
- Scelta degli identificatori primari



ELIMINAZIONE DELLE GERARCHIE

- entità e associazioni sono direttamente rappresentabili
- il modello relazionale non può rappresentare direttamente le generalizzazioni
- si eliminano perciò le gerarchie, sostituendole con entità e associazioni



TRE POSSIBILITÀ

- (1) accorpamento delle specializzazioni nella generalizzazione
- (2) accorpamento della generalizzazione nelle specializzazioni
(ove possibile)
- (3) sostituzione della generalizzazione con associazioni



CONSIDERAZIONI

- Conviene quando le operazioni accedono in prevalenza indifferentemente a tutte le specializzazioni e alla generalizzazione
- Svantaggio: molti valori nulli in corrispondenza degli attributi delle specializzazioni
- Se la generalizzazione è sovrapposta o si fa diventare **esclusiva** (es. alle specializzazioni studente e lavoratore aggiungo quella studente-lavoratore) oppure tipo prevede valori ad hoc (es. studente, lavoratore, studente-lavoratore)



CONSIDERAZIONI

- Conviene quando le operazioni accedono in prevalenza in maniera differenziata ai figli o al padre
- Svantaggio: questo metodo non è applicabile se la generalizzazione non è totale (ci sono occorrenze che non potrei collocare in nessuna specializzazione)



CONSIDERAZIONI

- Conviene quando le operazioni accedono in prevalenza in maniera differenziata ai figli o al padre e la generalizzazione non è totale
- Svantaggio: per recuperare tutti gli attributi dei figli occorre navigare nello schema (corrisponde ad effettuare dei join)

Sono anche possibili soluzioni ibride, soprattutto per gerarchie a più livelli



ATTIVITÀ DELLA RISTRUTTURAZIONE

- Analisi delle ridondanze
- Eliminazione delle generalizzazioni
- Partizionamento/accorpamento di entità e relazioni
- Scelta degli identificatori primari



- Ristrutturazioni effettuate per rendere più efficienti le operazioni in base a un semplice principio
- Gli accessi si riducono:
 - separando attributi di un concetto che vengono acceduti separatamente
 - raggruppando attributi di concetti diversi acceduti insieme (**pericoloso!**)




TIPOLOGIE


- partizionamento verticale di entità
- partizionamento orizzontale di associazioni
- eliminazione di attributi multivalore
- (accorpamento di entità/relazioni)



ESEMPIO: PARTIZIONAMENTO VERTICALE DI ENTITÀ

- Supponiamo che le nostre applicazioni accedono separatamente ai dati anagrafici o a quelli lavorativi di un impiegato
- Conviene separarli: se i record sono più piccoli, in una sola lettura dal disco (operazione costosa) riesco a portare più record in memoria









ESEMPIO: PARTIZIONAMENTO ORIZZONTALE DI ASSOCIAZIONI

- Supponiamo che la nostra applicazione acceda separatamente alla composizione attuale della squadra rispetto a quelle degli anni passati
- Separando i due tipi di collegamento lo schema risulta più chiaro e le operazioni più efficienti








ESEMPIO: ATTRIBUTO MULTIVALORE

- Gli attributi multivalore non sono rappresentabili direttamente nel modello relazionale. In questo caso il **partizionamento** dell'entità è obbligatorio per poter poi procedere alla traduzione





ATTIVITÀ DELLA RISTRUTTURAZIONE

- Analisi delle ridondanze
- Eliminazione delle generalizzazioni
- Partizionamento/accorpamento di entità e relazioni
- Scelta degli identificatori primari



CRITERI PER LA SCELTA DEGLI IDENTIFICATORI

- **attributo o attributi non opzionali** (non sono ammessi valori nulli)
- semplicità: tra i possibili identificatori **scegliere quelli con meno attributi**; a limite meglio aggiungere un codice “**artificiale**” ma ...
- preferenza per gli identificatori **interni**
- utilizzo nelle operazioni **più frequenti o importanti**

- **ATTENZIONE!** Ogni entità (e in seguito ogni tabella) deve avere un identificatore (chiave)
- Aspetto collegato anche allo studio delle **dipendenze funzionali**